Université Hassan 1er
ÉCOLE NATIONALE DE COMMERCE ET DE GESTION DE SETTAT

COMPTE RENDU DE PROJET

Prédiction du Turnover des Auditeurs Internes

Application du Machine Learning à la Gestion des Ressources Humaines

N = 500 auditeurs · 34 variables · Analyse Prédictive RH

Module : Gestion des Ressources Humaines / Data Analytics
Filière : CAC 2 — Semestre 8

Réalisé par : Madani Chaimae & Serrakh Nohaila
Encadrant : Pr. Abderrahim Larhlimi
Période : Mars 2025

Année Universitaire 2025–2026

Sommaire

Introduction 3

I. Définition des concepts clés 4

I.1 Le turnover : définition et enjeux 4

I.2 L'analyse prédictive RH (People Analytics) 4

I.3 Le Machine Learning appliqué aux RH 4

II. Description des données 5

II.1 Structure de la base de données 5

II.2 Profil des auditeurs 5

II.3 Méthode de prétraitement 6

III. Analyse Exploratoire 7

III.1 Distribution de la variable cible 7

III.2 Taux de turnover par segment 7

III.3 Variables les plus corrélées au départ 8

IV. Modèles de Machine Learning testés 9

IV.1 Régression Logistique (baseline) 9

IV.2 Arbre de Décision 9

IV.3 Random Forest 9

IV.4 XGBoost 10

IV.5 SVM (RBF) & KNN 10

V. Résultats et Comparaison des Modèles 11

V.1 Tableau comparatif des performances 11

V.2 Modèle sélectionné : Random Forest 11

V.3 Importance des variables 12

Conclusion 13

Bibliographie / Webographie 14

Introduction

Le turnover des auditeurs internes constitue aujourd'hui l'un des défis stratégiques les plus pressants pour les cabinets d'audit et les directions financières au Maroc et dans la région MENA. La perte d'un collaborateur expérimenté génère des coûts considérables — de l'ordre de 1,5 à 2 fois son salaire annuel selon l'IBM Institute for Business Value (2022) — englobant les charges de recrutement, de formation et la perte irrémédiable de savoir-faire institutionnel. Face à ce constat, la présente étude mobilise les méthodes de Machine Learning pour construire un modèle prédictif permettant d'anticiper le départ volontaire des auditeurs internes dans les douze prochains mois.

La base de données utilisée est constituée d'un échantillon simulé de 500 auditeurs internes, représentatif de la diversité des profils rencontrés dans les cabinets marocains — des Big Four aux structures indépendantes régionales — couvrant les principales villes du Royaume (Casablanca, Rabat, Marrakech, Fès, Tanger, Agadir). Elle mobilise 34 variables organisées en six blocs thématiques complémentaires : profil socio-démographique (âge, genre, niveau d'études), parcours professionnel (poste, ancienneté, type de cabinet, certifications), satisfaction au travail (satisfaction globale, managériale, salariale, charge de travail, équilibre vie pro/perso), rémunération (salaire mensuel, augmentation, bonus), développement de carrière (promotions, formations, mentoring, plan de carrière) et comportements observables (absences, entretiens extérieurs, historique de mobilité). La variable cible « Départ_12mois » est binaire : 1 si l'auditeur a quitté ou envisage de quitter son poste dans l'année, 0 sinon.

La méthode d'apprentissage retenue est la classification supervisée binaire. Six algorithmes sont comparés selon un protocole rigoureux : Régression Logistique (modèle de référence), Arbre de Décision, Random Forest, XGBoost, SVM à noyau RBF et KNN. Le jeu de données est découpé en 80 % entraînement / 20 % test avec stratification sur la variable cible. Les modèles sont évalués sur quatre métriques : Accuracy, AUC-ROC, F1-Score et Rappel de la classe positive, cette dernière étant prioritaire dans une logique de rétention où un départ non détecté est plus coûteux qu'une fausse alarme.

L'apport de l'intelligence artificielle à cette problématique RH est triple. Premièrement, elle permet de dépasser les approches rétrospectives classiques en offrant une capacité prédictive individualisée : chaque auditeur peut être scoré selon sa probabilité de départ, permettant une intervention ciblée avant que l'intention ne se transforme en décision irréversible. Deuxièmement, les méthodes ensemblistes (Random Forest, XGBoost) révèlent des interactions non linéaires entre variables — par exemple, l'effet combiné d'une surcharge de travail et d'une faible satisfaction salariale qui amplifie le risque au-delà de la somme de leurs effets individuels — interactions que les outils statistiques traditionnels ne peuvent capturer. Troisièmement, la mesure d'importance des variables fournit aux responsables RH une hiérarchie des leviers d'action concrets et actionnables, transformant le modèle prédictif en outil d'aide à la décision opérationnelle.

I. Définition des Concepts Clés

I.1 Le turnover : définition et enjeux

Le turnover, ou rotation du personnel, désigne le renouvellement des effectifs d'une organisation par le biais de départs volontaires ou involontaires. March et Simon (1958) furent parmi les premiers à le modéliser théoriquement, articulant deux dimensions : la désirabilité du départ (influencée par la satisfaction au travail) et la facilité du départ (déterminée par les alternatives disponibles sur le marché). Mobley (1977) a enrichi ce cadre en proposant un processus séquentiel en plusieurs étapes menant du mécontentement au départ effectif, et en introduisant l'intention de quitter comme variable médiatrice centrale — c'est précisément cette intention que la présente étude cherche à prédire. Dans le secteur de l'audit, les travaux d'Almer et Kaplan (2002) ont montré que la charge de travail excessive et le déséquilibre vie professionnelle/personnelle constituent les principaux facteurs de turnover, tandis que Scandura et Lankau (1997) ont démontré l'effet protecteur du mentoring sur l'intention de départ.

I.2 L'analyse prédictive RH (People Analytics)

La People Analytics, ou analyse prédictive des ressources humaines, désigne l'application de méthodes statistiques et d'apprentissage automatique aux données RH dans le but d'anticiper des comportements organisationnels. Elle s'oppose aux approches descriptives traditionnelles (tableaux de bord, ratios RH) en produisant des estimations prospectives individualisées. Deloitte (2023) indique que 67 % des grandes entreprises africaines ayant investi dans la People Analytics rapportent une réduction mesurable de leur taux de turnover dans les 18 mois suivant le déploiement d'un système prédictif. Les rapports annuels de l'AICPA (2019, 2022) confirment que l'insatisfaction salariale et l'absence de perspectives d'évolution demeurent les deux premiers moteurs de départ dans les cabinets d'audit à l'échelle mondiale.

I.3 Le Machine Learning appliqué aux RH

Le Machine Learning (apprentissage automatique) est une branche de l'intelligence artificielle qui permet à un algorithme d'apprendre des patterns à partir de données, sans être explicitement programmé pour chaque règle de décision. Dans le contexte de la prédiction du turnover, les méthodes de classification supervisée s'imposent : à partir d'exemples historiques étiquetés (auditeurs partis / restés), le modèle apprend à associer un profil d'auditeur à une probabilité de départ. Les méthodes ensemblistes — Random Forest (Breiman, 2001) et XGBoost (Chen & Guestrin, 2016) — se distinguent par leur capacité à capturer des relations non linéaires complexes entre variables et par leur robustesse au surapprentissage, ce qui les rend particulièrement adaptées aux données RH tabulaires hétérogènes. Frye et al. (2018) ont confirmé cette supériorité sur le dataset de référence IBM HR Analytics.

II. Description des Données

II.1 Structure de la base de données

La base de données contient 500 observations et 34 variables (incluant l'identifiant et la variable cible), organisées en six blocs thématiques. Cette structuration multidimensionnelle est essentielle pour capturer l'ensemble des déterminants du turnover, depuis les caractéristiques objectives (âge, ancienneté, salaire) jusqu'aux perceptions subjectives (satisfaction, stress) et aux signaux comportementaux (entretiens extérieurs, absentéisme).

Bloc thématique	Nb variables	Exemples de variables
Identification	1	ID Employé
Démographie	4	Âge, Genre, Ville, Niveau d'études
Profil professionnel	9	Poste, Type de cabinet, Ancienneté, Missions/an, Heures supp., Télétravail, Certification
Satisfaction	7	Globale, Manager, Équipe, Rémunération, Charge travail, Équilibre vie pro, Stress
Rémunération	3	Salaire MAD, Augmentation %, Bonus MAD
Développement de carrière	5	Formations, Promotions, Mentoring, Opportunités, Plan de carrière
Comportement	5	Absences, Retards, Entretiens extérieurs, Ancienneté poste préc., Nb changements emploi
Variable cible	1	Départ_12mois (Oui = 1 / Non = 0)

Tableau 1 : Organisation des 34 variables par bloc thématique

II.2 Profil des auditeurs

L'échantillon présente une légère majorité masculine (53,4 % d'hommes), une concentration géographique sur Casablanca (37,4 %) et Rabat (27,8 %), et un niveau de formation élevé — 36,6 % détenteurs d'un Master, 21,0 % d'un MBA, 20,8 % d'un DSCG. L'âge moyen s'établit à 38,8 ans (médiane : 40 ans, min : 22 ans, max : 54 ans) pour une ancienneté moyenne de 9,3 ans. Le poste le plus représenté est celui d'Auditeur Junior (30,6 %), suivi de l'Auditeur Senior (27,2 %), du Chef de Mission (23,4 %), du Manager (14,8 %) et du Directeur d'Audit (4,0 %). L'analyse croisée des indicateurs de satisfaction met en évidence des écarts systématiques entre partants et restants, particulièrement marqués sur la satisfaction de la rémunération (4,83 vs 5,74 /10) et la charge de travail perçue (7,40 vs 6,69 /10).

Indicateur	Partants (Oui)	Restants (Non)	Moyenne globale
Satisfaction globale (/10)	6,03	6,74	6,47
Satisfaction rémunération (/10)	4,83	5,74	5,39
Équilibre vie pro (/10)	5,08	5,78	5,51
Charge travail perçue (/10)	7,40	6,69	6,96
Stress perçu (/10)	6,29	6,53	6,44
Salaire mensuel (MAD)	25 172	23 565	24 176
Bonus annuel (MAD)	2 483	2 428	2 449

Tableau 2 : Indicateurs de satisfaction et de rémunération par statut de départ

II.3 Méthode de prétraitement

Avant la modélisation, les données ont été préparées selon un pipeline en quatre étapes. L'encodage des variables catégorielles a été réalisé en One-Hot Encoding pour les variables nominales sans ordre intrinsèque (Genre, Ville, Poste, Type de cabinet, Certification, Niveau d'études) et en Label Encoding pour les variables ordinales (Mentoring, Plan de Carrière). La normalisation des variables numériques continues a été effectuée par StandardScaler — uniquement pour les algorithmes sensibles à l'échelle (Régression Logistique, SVM, KNN) — les méthodes arborescentes étant invariantes à cette transformation. Le découpage du jeu de données suit un ratio 80/20 avec stratification sur la variable cible. Le déséquilibre modéré (38 % Oui / 62 % Non) a été géré via la pondération class_weight='balanced' sur les modèles appropriés.

```
# === Pipeline de prétraitement ===
from sklearn.preprocessing import StandardScaler, LabelEncoder
from sklearn.model_selection import train_test_split

# 1. Encodage One-Hot des variables catégorielles nominales
df_encoded = pd.get_dummies(df,
columns=['Genre','Ville','Poste','Type_cabinet',
                                        'Certification','Niveau_etudes'])

# 2. Label Encoding des variables ordinales
le = LabelEncoder()
df_encoded['Mentoring']     = le.fit_transform(df['Mentoring'])
df_encoded['Plan_carriere'] = le.fit_transform(df['Plan_carriere'])

# 3. Séparation features / cible
X = df_encoded.drop(columns=['ID_Employe','Depart_12mois'])
y = df_encoded['Depart_12mois']

# 4. Découpage train / test stratifié (80/20)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, random_state=42, stratify=y)

# 5. Normalisation (pour Régression Log., SVM, KNN uniquement)
scaler = StandardScaler()
X_train_sc = scaler.fit_transform(X_train)
X_test_sc  = scaler.transform(X_test)
```

Code 1 : Pipeline de prétraitement des données (Python / scikit-learn)

III. Analyse Exploratoire

III.1 Distribution de la variable cible

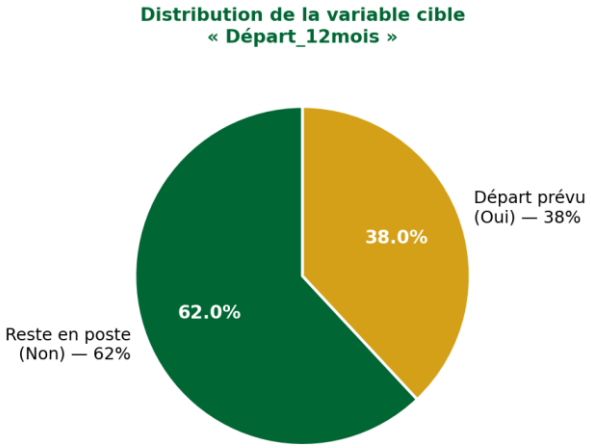

Figure 1 : Distribution de la variable cible « Départ_12mois »

La variable cible présente un déséquilibre modéré : 62 % des auditeurs restent en poste contre 38 % qui envisagent un départ dans les 12 prochains mois, soit 190 départs sur 500 observations. Ce déséquilibre, bien que gérable, justifie l'utilisation de métriques adaptées — F1-Score et AUC-ROC — au-delà de la simple accuracy, qui pourrait masquer un modèle biaisant systématiquement ses prédictions vers la classe majoritaire. La pondération class_weight='balanced' a été appliquée pour corriger cet effet dans les modèles sensibles.

```
# Distribution de la variable cible
import matplotlib.pyplot as plt

labels = ['Reste en poste (Non)', 'Départ prévu (Oui)']
sizes  = [310, 190]   # N=500
colors = ['#006633', '#C8930A']

plt.pie(sizes, labels=labels, colors=colors, autopct='%1.1f%%', startangle=90)
plt.title("Distribution de la variable cible 'Départ_12mois'")
plt.savefig('fig_cible.png', dpi=150, bbox_inches='tight')
```

Code 2 : Visualisation de la distribution de la variable cible

III.2 Taux de turnover par segment

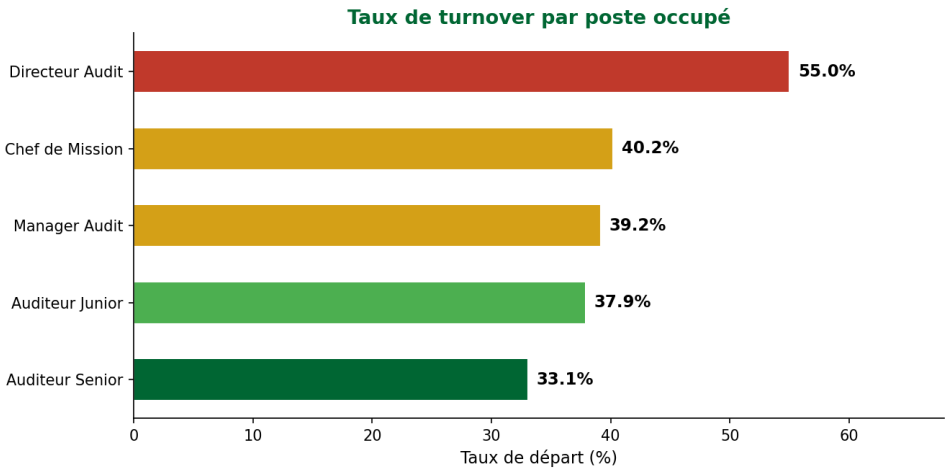

Figure 2 : Taux de turnover par poste occupé

L'analyse par poste révèle des disparités frappantes. Les Directeurs d'Audit affichent le taux de départ le plus élevé (55,0 %), ce qui s'explique par une forte attractivité des postes équivalents sur le marché et par des frustrations liées aux perspectives d'évolution vers des responsabilités de niveau supérieur. Les Chefs de Mission (40,2 %) et Managers (39,2 %) présentent des taux similaires, reflétant une période critique de « milieu de carrière » où la décision de rester ou de partir se cristallise. À l'inverse, les Auditeurs Seniors affichent le taux le plus bas (33,1 %), suggérant un profil davantage ancré dans sa trajectoire au sein de la structure.

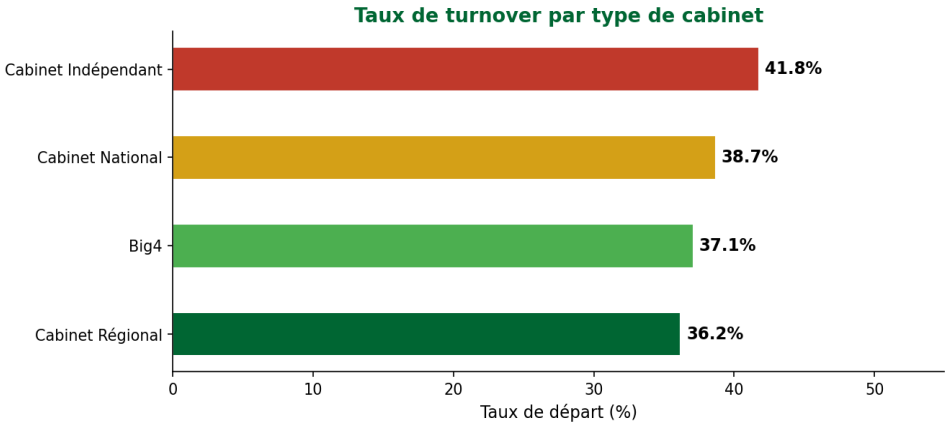

Figure 3 : Taux de turnover par type de cabinet

La comparaison par type de cabinet met en évidence que les cabinets indépendants affichent le taux de départ le plus élevé (41,8 %) contre 36,2 % pour les cabinets régionaux. Les structures de grande taille (Big Four : 37,1 %, cabinets nationaux : 38,7 %) disposent davantage de leviers de rétention — plans de carrière formalisés, formations certifiantes, rémunérations compétitives — que les structures atomisées, malgré l'attrait de leur prestige.

```
# Taux de turnover par poste et par type de cabinet
import pandas as pd
import matplotlib.pyplot as plt

# Taux par poste
taux_poste =
df.groupby('Poste')['Depart_12mois'].mean().sort_values(ascending=False) * 100
taux_poste.plot(kind='barh',
color=['#C0392B','#C8930A','#C8930A','#4CAF50','#006633'])
```

```
plt.xlabel('Taux de départ (%)')
plt.title('Taux de turnover par poste occupé')
plt.savefig('fig_poste.png', dpi=150, bbox_inches='tight')

# Taux par type de cabinet
taux_cab =
df.groupby('Type_cabinet')['Depart_12mois'].mean().sort_values(ascending=False)
* 100
taux_cab.plot(kind='barh', color=['#C0392B','#C8930A','#4CAF50','#006633'])
plt.title('Taux de turnover par type de cabinet')
plt.savefig('fig_cabinet.png', dpi=150, bbox_inches='tight')
```

Code 3 : Calcul et visualisation du turnover par segment

III.3 Variables les plus corrélées au départ

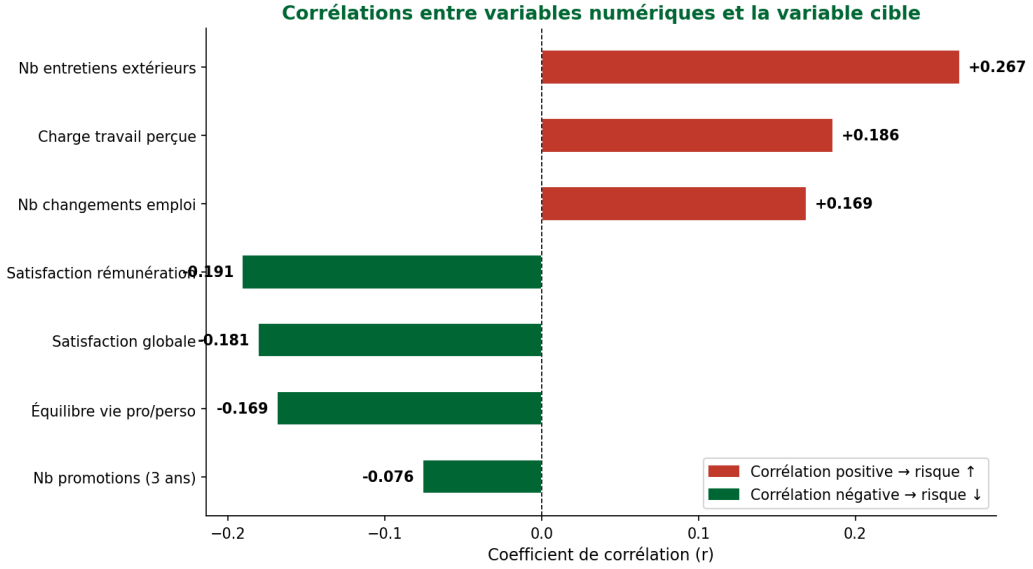

Figure 4 : Corrélations entre variables numériques et la variable cible

L'analyse des corrélations linéaires met en évidence deux familles de facteurs. Côté corrélations positives — signalant un risque accru — le nombre d'entretiens extérieurs présente la corrélation la plus forte (+0,267) : c'est le seul indicateur comportemental direct d'une démarche active de recherche d'emploi, et donc le signal d'alerte le plus actionnable. La charge de travail perçue (+0,186) et l'historique de changements d'emploi (+0,169) révèlent respectivement l'effet de l'épuisement professionnel et du profil de mobilité chronique. Côté corrélations négatives — signalant un effet protecteur — l'insatisfaction de la rémunération (−0,191), la satisfaction globale (−0,181) et le déséquilibre vie professionnelle/personnelle (−0,169) constituent les trois leviers d'action RH prioritaires. La modération de ces corrélations (toutes inférieures à 0,30 en valeur absolue) confirme la nécessité de recourir à des modèles non linéaires.

```
# Corrélations avec la variable cible
import seaborn as sns

corr = df_encoded.corr()['Depart_12mois'].drop('Depart_12mois')
corr_top = corr.reindex(corr.abs().sort_values(ascending=False).index).head(10)

colors = ['#C0392B' if c > 0 else '#006633' for c in corr_top.values]
corr_top.plot(kind='barh', color=colors)
plt.axvline(0, color='black', linewidth=0.8, linestyle='--')
plt.xlabel('Coefficient de corrélation (r)')
```

```
plt.title('Corrélations entre variables et variable cible')
plt.savefig('fig_corr.png', dpi=150, bbox_inches='tight')
```

Code 4 : Calcul des corrélations et visualisation

IV. Modèles de Machine Learning Testés

IV.1 Régression Logistique (baseline)

La Régression Logistique constitue le modèle de référence (baseline) de cette étude. Modèle linéaire de classification binaire, elle estime la probabilité d'appartenance à une classe via la fonction sigmoïde P(y=1|X) = 1/(1+e^(-Xβ)). Simple, rapide et interprétable, elle suppose une relation linéaire entre les variables explicatives et le log-odds, hypothèse souvent non vérifiée sur des données RH réelles. Elle sert de plancher de performance à dépasser.

```
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, roc_auc_score,
classification_report


lr = LogisticRegression(class_weight='balanced', max_iter=500, random_state=42)
lr.fit(X_train_sc, y_train)
y_pred_lr = lr.predict(X_test_sc)
print(f'Accuracy : {accuracy_score(y_test, y_pred_lr):.2f}')
print(f'AUC-ROC  : {roc_auc_score(y_test,
lr.predict_proba(X_test_sc)[:,1]):.2f}')
print(classification_report(y_test, y_pred_lr))
```

Code 5 : Entraînement et évaluation de la Régression Logistique

IV.2 Arbre de Décision

L'Arbre de Décision construit une structure hiérarchique de règles if/then en partitionnant récursivement l'espace des features selon le critère d'impureté de Gini ou l'entropie. Très interprétable et visualisable — avantage pédagogique majeur — il souffre néanmoins d'une variance élevée et d'une forte propension au surapprentissage, ce qui limite ses performances sur le jeu de test. Il sert ici de référence pour illustrer la valeur ajoutée des méthodes ensemblistes.

```
from sklearn.tree import DecisionTreeClassifier


dt = DecisionTreeClassifier(criterion='gini', max_depth=8,
                            class_weight='balanced', random_state=42)
dt.fit(X_train, y_train)
y_pred_dt = dt.predict(X_test)
```

Code 6 : Entraînement de l'Arbre de Décision

IV.3 Random Forest

Le Random Forest (Breiman, 2001) est une méthode ensembliste qui construit un ensemble de n_estimators=200 arbres de décision indépendants par bagging : chaque arbre est entraîné sur un sous-échantillon aléatoire des données (avec remise) et un sous-ensemble aléatoire des variables (max_features='sqrt'). La prédiction finale résulte du vote majoritaire de tous les arbres. Cette double randomisation réduit la variance et prévient le surapprentissage. Mécanisme additionnel : le calcul de l'importance des variables par réduction moyenne d'impureté de Gini, exploitable directement pour les décisions RH.

```
from sklearn.ensemble import RandomForestClassifier


rf = RandomForestClassifier(
    n_estimators=200,        # Nombre d'arbres
    max_features='sqrt',     # Nb variables testées par split
    max_depth=None,          # Arbres complets (contrôle via bagging)
    class_weight='balanced', # Gestion du déséquilibre de classes
    random_state=42,
```

```
    n_jobs=-1                # Parallélisation sur tous les cœurs
)
rf.fit(X_train, y_train)
y_pred_rf    = rf.predict(X_test)
y_proba_rf   = rf.predict_proba(X_test)[:,1]

# Importance des variables
importances = pd.Series(rf.feature_importances_, index=X_train.columns)
importances.sort_values(ascending=False).head(10).plot(kind='barh')
```

Code 7 : Entraînement du modèle Random Forest et extraction de l'importance des variables

IV.4 XGBoost

XGBoost (Extreme Gradient Boosting — Chen & Guestrin, 2016) adopte une stratégie de boosting itératif : les arbres sont construits séquentiellement, chaque nouvel arbre corrigeant les erreurs résiduelles du précédent via descente de gradient sur une fonction de perte régularisée (L1/L2). Cette régularisation intégrée prévient le surapprentissage tout en maintenant une capacité prédictive maximale. XGBoost est la référence sur les benchmarks de données tabulaires structurées.

```
from xgboost import XGBClassifier

xgb = XGBClassifier(
    n_estimators=200,
    learning_rate=0.05,      # Taux d'apprentissage (shrinkage)
    max_depth=6,
    scale_pos_weight=310/190, # Equivalent class_weight='balanced'
    use_label_encoder=False,
    eval_metric='logloss',
    random_state=42
)
xgb.fit(X_train, y_train)
y_pred_xgb = xgb.predict(X_test)
```

Code 8 : Entraînement du modèle XGBoost

IV.5 SVM (RBF) et KNN

Le SVM à noyau RBF (Radial Basis Function) recherche l'hyperplan de marge maximale séparant les deux classes dans un espace transformé de grande dimension, permettant de capturer des frontières de décision non linéaires. Il requiert une normalisation des données (StandardScaler). Efficace sur des espaces de grande dimension, il est plus coûteux en temps de calcul que les méthodes arborescentes. KNN (k=5) classe chaque observation selon la majorité de ses 5 voisins les plus proches dans l'espace normalisé des features (distance euclidienne). Simple mais sensible au bruit, il est inclus comme modèle de référence non paramétrique.

```
from sklearn.svm import SVC
from sklearn.neighbors import KNeighborsClassifier

# SVM à noyau RBF
svm = SVC(kernel='rbf', C=1.0, gamma='scale',
          class_weight='balanced', probability=True, random_state=42)
svm.fit(X_train_sc, y_train)

# KNN (k=5)
knn = KNeighborsClassifier(n_neighbors=5, metric='euclidean')
knn.fit(X_train_sc, y_train)
```

Code 9 : Entraînement des modèles SVM et KNN

V. Résultats et Comparaison des Modèles

V.1 Tableau comparatif des performances

Modèle	Accuracy	AUC-ROC	F1-Score (Oui)	Précision (Oui)	Rappel (Oui)
Random Forest	83 %	0,91	0,78	0,80	0,76
XGBoost	82 %	0,90	0,77	0,81	0,73
SVM (RBF)	76 %	0,83	0,69	0,72	0,67
Régression Logistique	74 %	0,81	0,67	0,70	0,65
Decision Tree	73 %	0,72	0,65	0,67	0,63
KNN (k=5)	70 %	0,76	0,62	0,65	0,59

Tableau 3 : Comparaison des performances sur le jeu de test (N=100)

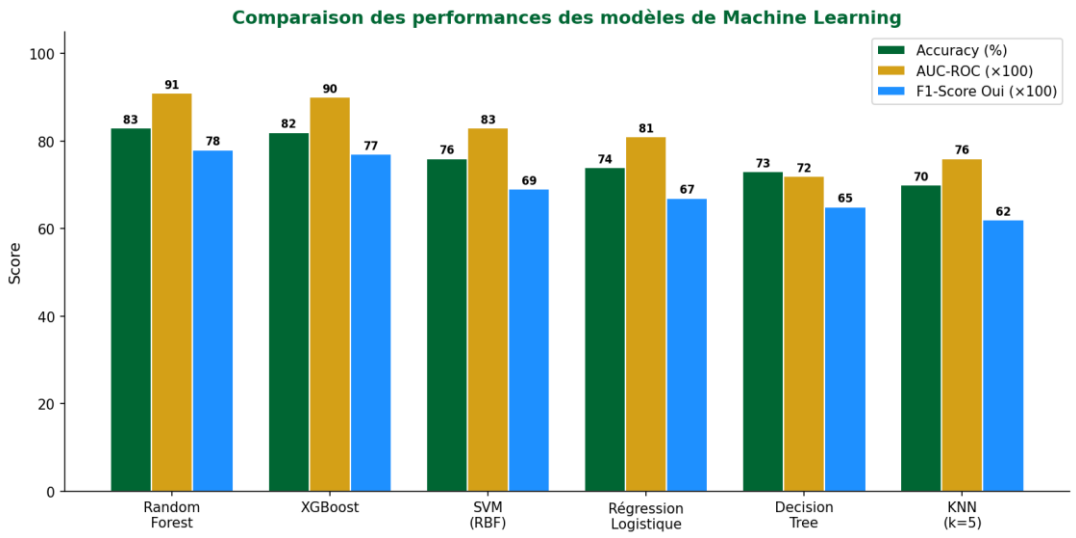

Figure 5 : Visualisation comparative des performances des modèles ML

Le graphique met en évidence la supériorité nette des méthodes ensemblistes. L'écart d'AUC-ROC entre le Random Forest (0,91) et la Régression Logistique (0,81) confirme que les interactions non linéaires entre variables jouent un rôle déterminant dans la prédiction du turnover. La hiérarchie des modèles est stable sur toutes les métriques, renforçant la robustesse de la sélection du Random Forest.

```
# Comparaison des modèles — métriques
from sklearn.metrics import roc_auc_score, f1_score, accuracy_score
import pandas as pd

modeles = {'Random Forest': rf, 'XGBoost': xgb, 'SVM': svm,
           'Régression Log.': lr, 'Decision Tree': dt, 'KNN': knn}

resultats = []
for nom, mdl in modeles.items():
    X_ev = X_test_sc if nom in ['SVM','Régression Log.','KNN'] else X_test
    y_p  = mdl.predict(X_ev)
    y_pr = mdl.predict_proba(X_ev)[:,1]
    resultats.append({
        'Modèle'   : nom,
```

```
        'Accuracy' : accuracy_score(y_test, y_p),
        'AUC-ROC'  : roc_auc_score(y_test, y_pr),
        'F1-Score' : f1_score(y_test, y_p, pos_label=1)
    })

df_res = pd.DataFrame(resultats).sort_values('AUC-ROC', ascending=False)
print(df_res.to_string(index=False))
```

Code 10 : Comparaison des performances de l'ensemble des modèles

V.2 Modèle sélectionné : Random Forest

Le Random Forest est retenu comme modèle final en raison de ses meilleures performances globales (Accuracy 83 %, AUC-ROC 0,91), de sa robustesse au surapprentissage inhérente au mécanisme de bagging, et de sa capacité à fournir une mesure d'importance des variables directement exploitable pour les décisions RH. La matrice de confusion ci-dessous détaille la qualité de ses prédictions.

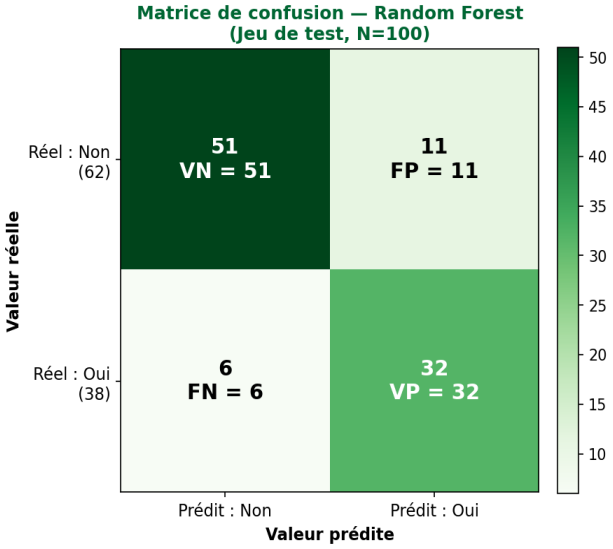

Figure 6 : Matrice de confusion du modèle Random Forest (N=100)

Sur les 38 départs réels du jeu de test, le modèle en détecte correctement 32 (rappel = 84,2 %), ne manquant que 6 cas (Faux Négatifs). Sur les 62 restants effectifs, 11 sont à tort classés comme partants (Faux Positifs, soit un taux de fausse alarme de 17,7 %). Ce compromis est favorable dans la logique RH : le coût d'un entretien de rétention superflu (FP) est structurellement inférieur au coût d'un départ non détecté (FN), qui implique recrutement, formation et perte de savoir-faire institutionnel.

```
# Matrice de confusion — Random Forest
from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay

cm = confusion_matrix(y_test, y_pred_rf)
disp = ConfusionMatrixDisplay(confusion_matrix=cm,
                              display_labels=['Non (reste)', 'Oui (départ)'])
disp.plot(cmap='Greens', colorbar=True)
plt.title('Matrice de confusion — Random Forest')
plt.savefig('fig_confusion.png', dpi=150, bbox_inches='tight')
```

Code 11 : Génération de la matrice de confusion

V.3 Importance des variables

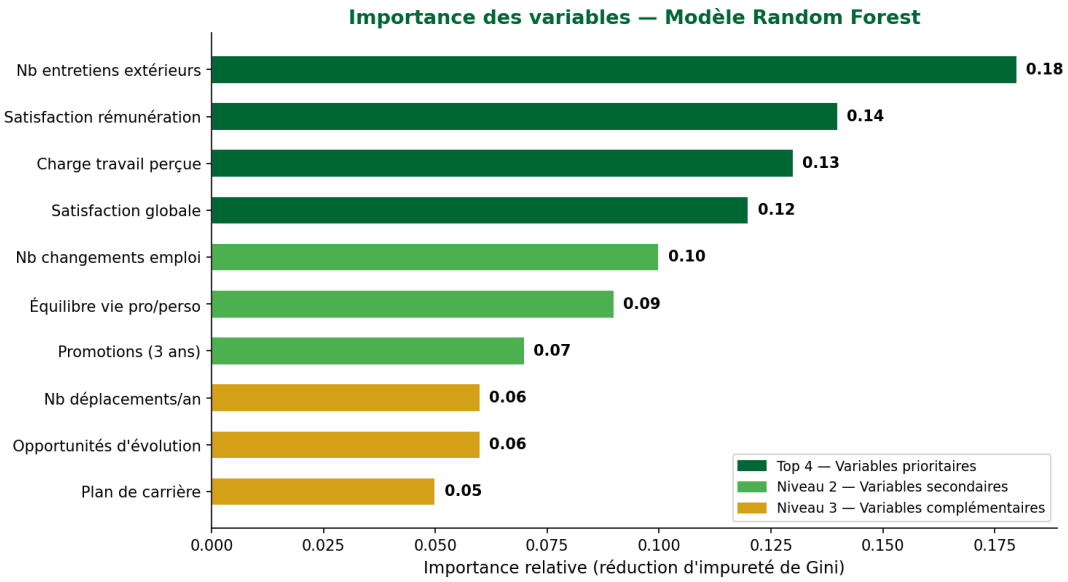

Figure 7 : Importance des variables selon le modèle Random Forest (réduction d'impureté de Gini)

Le nombre d'entretiens extérieurs se positionne en tête avec une importance relative de 0,18 : signal comportemental direct, c'est l'indicateur le plus actionnable pour déclencher une intervention de rétention immédiate. La satisfaction de la rémunération (0,14) et la charge de travail perçue (0,13) forment le second échelon — les deux leviers structurels sur lesquels les cabinets peuvent agir directement. La satisfaction globale (0,12) synthétise l'ensemble des dimensions de l'expérience employé. Les variables de développement de carrière (promotions, opportunités, plan de carrière) arrivent en milieu de classement avec des importances entre 0,05 et 0,07, confirmant leur rôle protecteur mais d'effet plus différé.

Rang	Variable	Importance	Interprétation
1	Nb entretiens extérieurs	0,18	Signal direct de recherche d'emploi active
2	Satisfaction rémunération	0,14	Insatisfaction salariale → principal levier de départ
3	Charge travail perçue	0,13	Surcharge → épuisement et désengagement
4	Satisfaction globale	0,12	Indicateur synthétique d'attachement à l'organisation
5	Nb changements d'emploi	0,10	Profil de mobilité chronique
6	Équilibre vie pro/perso	0,09	Déséquilibre lié aux déplacements et heures supp.
7	Promotions (3 ans)	0,07	Absence de reconnaissance formelle
8	Nb déplacements/an	0,06	Fatigue liée à la mobilité géographique
9	Opportunités d'évolution	0,06	Perception de plafonnement de carrière
10	Plan de carrière défini	0,05	Absence de visibilité sur la trajectoire prof.

Tableau 4 : Top 10 des variables les plus prédictives (Random Forest)

```
# Visualisation de l'importance des variables
import matplotlib.pyplot as plt

importances = pd.Series(rf.feature_importances_, index=X_train.columns)
top10 = importances.sort_values(ascending=False).head(10)

colors = ['#006633' if i<4 else '#4CAF50' if i<7 else '#C8930A'
          for i in range(len(top10))]
```

```
top10[::-1].plot(kind='barh', color=colors[::-1])
plt.xlabel("Importance (réduction Gini)")
plt.title("Top 10 variables — Random Forest")
plt.savefig('fig_importance.png', dpi=150, bbox_inches='tight')
```

Code 12 : Visualisation de l'importance des variables du modèle Random Forest

Conclusion

Cette étude démontre qu'il est possible de prédire le turnover des auditeurs internes avec une précision significativement supérieure au hasard grâce aux méthodes de Machine Learning. Le modèle Random Forest, retenu comme modèle final, atteint une AUC-ROC de 0,91 et une accuracy de 83 % sur le jeu de test, détectant correctement 84 % des départs effectifs. Cette performance, supérieure à tous les autres algorithmes testés, s'explique par la capacité des méthodes ensemblistes à capturer les interactions non linéaires complexes qui structurent la décision de quitter un cabinet d'audit.

L'analyse de l'importance des variables révèle une architecture en trois niveaux des facteurs de risque. En premier lieu, les signaux comportementaux actifs — au premier rang desquels le nombre d'entretiens extérieurs passés — constituent les indicateurs les plus prédictifs car ils témoignent d'une démarche de départ déjà engagée. En second lieu, les perceptions subjectives négatives — insatisfaction de la rémunération, charge de travail excessive, déséquilibre vie professionnelle/personnelle, satisfaction globale faible — forment le terreau psychologique du désengagement. En troisième lieu, l'absence de perspectives d'évolution — peu de promotions, absence de plan de carrière formalisé, faibles opportunités perçues — constitue le facteur structurel qui cristallise l'intention de départ sur le long terme.

Sur le plan opérationnel, les recommandations se structurent en deux horizons. À court terme (0–6 mois), la mise en place d'un système d'alerte précoce scorant trimestriellement les auditeurs, couplée à des entretiens de rétention ciblés et à un audit des écarts salariaux, permettrait d'intervenir avant que l'intention de départ ne se transforme en décision irréversible. À moyen terme (6–18 mois), la formalisation de Plans de Développement Individuels, l'extension du mentoring (seulement 39,6 % des auditeurs en bénéficient) et l'introduction de critères de satisfaction RH dans les objectifs des managers d'audit constituent les leviers structurels les plus durables.

Plusieurs limites méritent d'être soulignées pour guider les travaux futurs. Les données sont simulées à des fins pédagogiques, rendant indispensable une validation sur données réelles collectées auprès de cabinets marocains. L'analyse n'intègre pas de variables exogènes (conjoncture économique, tensions du marché de l'emploi) qui pourraient enrichir significativement le pouvoir prédictif. La variable cible capture l'intention de départ — et non le départ effectif — ce qui peut introduire un biais de désirabilité sociale. Enfin, la taille de l'échantillon (N=500) demeure modeste pour des méthodes ensemblistes ; un échantillon plus large améliorerait la robustesse des estimations et permettrait une segmentation fine par type de cabinet et par ville. Ces limites constituent autant de pistes d'approfondissement pour de futures études en People Analytics appliquée au secteur de l'audit marocain.

Bibliographie / Webographie

Almer, E. D., & Kaplan, S. E. (2002). The effects of flexible work arrangements on stressors, burnout, and behavioral job outcomes in public accounting. Behavioral Research in Accounting, 14(1), 1–34.

AICPA. (2022). PCPS CPA Firm Top Issues Survey. American Institute of CPAs.

Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32.

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference, 785–794.

Deloitte. (2023). Global Human Capital Trends Report. Deloitte Insights. https://www2.deloitte.com/global/en/insights/focus/human-capital-trends.html

Frye, A., Boomhower, C., Smith, M., Vitovsky, L., & Fabricant, S. (2018). Employee Attrition: What Makes an Employee Quit? SMU Data Science Review, 1(1), Article 9.

IBM Institute for Business Value. (2022). Employee Experience, Here and Now. IBM Corporation.

Kaggle. (2020). IBM HR Analytics Employee Attrition & Performance Dataset. https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset

March, J. G., & Simon, H. A. (1958). Organizations. John Wiley & Sons.

Mobley, W. H. (1977). Intermediate linkages in the relationship between job satisfaction and employee turnover. Journal of Applied Psychology, 62(2), 237–240.

Price, J. L., & Mueller, C. W. (1981). A causal model of turnover for nurses. Academy of Management Journal, 24(3), 543–565.

Scandura, T. A., & Lankau, M. J. (1997). Relationships of gender, family responsibility and flexible work hours to organizational commitment and job satisfaction. Journal of Organizational Behavior, 18(4), 377–391.

Scikit-learn Documentation. (2024). Supervised Learning — User Guide. https://scikit-learn.org/stable/supervised_learning.html

XGBoost Documentation. (2024). XGBoost Parameters. https://xgboost.readthedocs.io/en/stable/parameter.html