Université Hassan 1er

ÉCOLE NATIONALE DE COMMERCE ET DE GESTION DE SETTAT

COMPTE RENDU DE PROJET

Prédiction du Turnover des Auditeurs Internes

Application du Machine Learning à la Gestion des Ressources Humaines

N = 500 auditeurs · 34 variables · Machine Learning appliqué aux RH

Module : Gestion des Ressources Humaines / Data Analytics

Filière : CAC 2 — S8

Réalisé par :

Madani Chaimae

Serrakh Nohaila

Encadrant : *Abderrahim larhlimi*

Période : Mars 2025

Année Universitaire 2025–2026

SOMMAIRE

Avant-propos / Note de contexte 3

I. Introduction 4

I.1 Contexte général 4

I.2 Objectifs de l'étude 4

I.3 Définition de la variable cible 5

II. Description des données 5

II.1 Structure de la base de données 5

II.2 Profil des auditeurs 6

III. Analyse Exploratoire 7

III.1 Taux de turnover par segment 7

III.2 Variables les plus corrélées au départ 8

IV. Modèles de Machine Learning testés 9

IV.1 Méthodologie de prétraitement 9

IV.2 Présentation des algorithmes 9

V. Résultats et Comparaison des Modèles 11

V.1 Tableau comparatif des performances 11

V.2 Modèle sélectionné : Random Forest 11

V.3 Importance des variables 12

VI. Conclusion et Recommandations 13

VI.1 Synthèse des enseignements 13

VI.2 Recommandations RH 13

VI.3 Limites de l'étude 14

Lien DEMO : https://drive.google.com/file/d/1BxRplw_ZEEpPJb_uMwAif_iQVuj-_Hqb/view?usp=sharing

Bibliographie / Webographie 15

AVANT-PROPOS — NOTE DE CONTEXTE

Contexte académique et pédagogique

Le présent compte rendu est réalisé dans le cadre du Semestre 8 (S8) de la filière Comptabilité, Audit et Contrôle (CAC 2) à l'École Nationale de Commerce et de Gestion de Settat (ENCG Settat), relevant de l'Université Hassan 1er. Il s'inscrit dans une unité d'enseignement combinant les fondamentaux de la gestion des ressources humaines et les approches quantitatives issues de la data science appliquée aux organisations.

Ce travail a été réalisé en binôme par Madani Chaimae et Serrakh Nohaila, durant le mois de mars 2025, sous l'encadrement d'un enseignant-chercheur du département Comptabilité et Audit de l'ENCG Settat.

Contexte thématique : le turnover dans les métiers de l'audit

Le marché de l'audit interne et externe au Maroc connaît depuis plusieurs années une tension structurelle autour de la rétention des talents. Les cabinets d'audit, qu'ils soient de dimension internationale (Big Four), nationale ou régionale, font face à un taux de rotation élevé de leurs équipes, particulièrement parmi les profils juniors et les cadres de direction. Ce phénomène, désigné sous le terme de turnover, désigne le renouvellement des effectifs d'une organisation par le biais de départs volontaires ou involontaires.

Le turnover engendre des coûts multidimensionnels pour les organisations concernées. Les coûts directs comprennent les charges liées au recrutement (annonces, processus de sélection, honoraires de cabinets de recrutement), à l'intégration et à la formation des nouveaux collaborateurs. Les coûts indirects, souvent sous-estimés, incluent la perte de savoir-faire institutionnel, la désorganisation des équipes, la dégradation de la qualité des missions d'audit en cours, ainsi que l'impact négatif sur la réputation de l'organisation auprès de ses clients.

Dans un contexte où le capital humain représente la ressource fondamentale des métiers intellectuels tels que l'audit, la capacité à anticiper et à prévenir les départs devient un enjeu de performance organisationnelle à part entière. Les organisations les

plus avancées s'orientent aujourd'hui vers des approches prédictives fondées sur l'analyse de données RH, permettant de dépasser les diagnostics rétrospectifs classiques pour adopter une posture proactive.

Contexte technologique : l'apport du Machine Learning aux RH

L'essor des méthodes d'apprentissage automatique (Machine Learning) offre aux professionnels des ressources humaines des outils puissants pour analyser de grands volumes de données et identifier des patterns prédictifs complexes, difficilement détectables par des approches statistiques classiques. Appliqué à la problématique du turnover, le Machine Learning permet de construire des modèles capables d'estimer, pour chaque collaborateur, une probabilité de départ à un horizon temporel donné, en s'appuyant sur des variables comportementales, attitudinales, rémunératoires et organisationnelles.

Cette approche, connue sous le nom d'Analyse Prédictive RH (Predictive HR Analytics), est en pleine expansion à l'échelle mondiale. Elle permet non seulement de prioriser les efforts de rétention, mais aussi d'identifier les leviers d'action les plus efficaces pour chaque profil d'employé. Plusieurs études académiques et rapports professionnels (IBM Institute for Business Value, Deloitte Human Capital Trends) ont démontré l'efficacité de ces méthodes pour réduire significativement les taux de départ volontaire.

Périmètre et données de l'étude

La présente étude porte sur un échantillon simulé de 500 auditeurs internes, représentatif de la diversité des profils rencontrés dans les cabinets d'audit marocains. Cet échantillon couvre les principales villes du Royaume (Casablanca, Rabat, Marrakech, Fès, Tanger, Agadir), différents types de structures (Big Four, cabinets nationaux, cabinets régionaux, cabinets indépendants) et une variété de postes allant de l'Auditeur Junior au Directeur d'Audit. Les données mobilisent 34 variables couvrant des dimensions socio-démographiques, professionnelles, comportementales, attitudinales et rémunératoires.

Il est important de souligner que ces données ont été générées à des fins pédagogiques. Si les distributions statistiques et les relations entre variables ont été

calibrées pour refléter des tendances réalistes du marché marocain de l'audit, une validation sur données réelles demeure indispensable avant tout déploiement opérationnel des modèles développés.

I. INTRODUCTION

I.1 Contexte général

Le turnover des auditeurs internes constitue aujourd'hui l'un des enjeux stratégiques majeurs pour les cabinets d'audit et les directions financières au Maroc et dans la région MENA. La perte d'auditeurs expérimentés engendre des coûts directs et indirects considérables : recrutement, formation, perte de savoir-faire institutionnel et impact sur la qualité des missions.

Face à ce constat, la prédiction du turnover par des méthodes de Machine Learning offre une opportunité unique d'identifier en amont les collaborateurs à risque de départ et d'orienter les actions de rétention de manière ciblée et proactive. Ce rapport présente une analyse complète réalisée sur une base de données de 500 auditeurs internes répartis dans les principales villes marocaines.

I.2 Objectifs de l'étude

- Identifier les facteurs clés déterminant le départ d'un auditeur dans les 12 prochains mois.
- Comparer plusieurs algorithmes de classification supervisée pour prédire ce départ.
- Sélectionner le modèle le plus performant et interpréter ses résultats pour guider la politique RH.
- Formuler des recommandations concrètes et actionnables pour réduire le taux de turnover.

I.3 Définition de la variable cible

La variable cible « Depart_12mois » est une variable binaire indiquant si l'auditeur a quitté ou envisage de quitter son poste dans les 12 prochains mois (Oui = 1 / Non = 0). Sur les 500 observations, 190 auditeurs présentent un départ anticipé (38,0 %) et 310 restent en poste (62,0 %).

Statut	Effectif	Proportion
Reste en poste (Non)	310	62,0 %
Départ prévu (Oui)	190	38,0 %
Total	500	100,0 %

Tableau 1 : Répartition de la variable cible « Départ dans les 12 mois »

II. DESCRIPTION DES DONNÉES

II.1 Structure de la base de données

La base de données contient 500 observations et 34 variables (incluant l'identifiant et la variable cible). Les variables sont organisées en 6 blocs thématiques couvrant le profil socio-démographique, le parcours professionnel, la satisfaction au travail, la rémunération, le développement de carrière et les comportements observables.

Bloc thématique	Nb variables	Exemples de variables
Identification	1	ID Employé
Démographie	4	Âge, Genre, Ville, Niveau d'études
Profil professionnel	9	Poste, Type de cabinet, Ancienneté, Missions/an, Heures supp., Déplacements, Télétravail, Certification
Satisfaction	7	Globale, Manager, Équipe, Rémunération, Charge travail, Équilibre vie pro, Stress
Rémunération	3	Salaire MAD, Augmentation %, Bonus MAD
Développement de carrière	5	Formations, Promotions, Mentoring, Opportunités, Plan de carrière
Comportement	5	Absences, Retards, Entretiens extérieurs, Ancienneté poste précédent, Nb changements d'emploi
Variable cible	1	Départ 12 mois (Oui/Non)

Tableau 2 : Organisation des variables par bloc thématique

II.2 Profil des auditeurs

Caractéristiques socio-démographiques

Variable	Modalité principale	Distribution
Genre	Homme	53,4 % Hommes / 46,6 % Femmes
Ville	Casablanca	Casablanca 37,4 % · Rabat 27,8 % · Marrakech 14,6 %
Niveau d'études	Master	Master 36,6 % · MBA 21,0 % · DSCG 20,8 %
Certification	Aucune	Aucune 34,0 % · CIA 27,4 % · CISA 16,4 % · CPA 13,4 %
Âge moyen	38,8 ans	Min : 22 ans · Max : 54 ans · Médiane : 40 ans

Tableau 3 : Caractéristiques socio-démographiques des auditeurs

Profil professionnel

Variable	Modalité principale	Distribution
Poste	Auditeur Junior	Junior 30,6 % · Senior 27,2 % · Chef mission 23,4 % · Manager 14,8 % · Directeur 4,0 %
Type de cabinet	Cabinet National	National 31,0 % · Big4 30,2 % · Régional 25,4 % · Indépendant 13,4 %
Ancienneté	9,3 ans (moy.)	Min : 0 an · Max : 19 ans · Médiane : 9 ans
Missions/an	7,8 (moy.)	Min : 2 · Max : 15 · Médiane : 8
Heures supp./sem.	11,2 h (moy.)	Min : 0 h · Max : 26 h · Médiane : 11 h
Déplacements/an	25,0 (moy.)	Min : 0 · Max : 49 · Médiane : 24,5

Tableau 4 : Profil professionnel des auditeurs

Satisfaction et rémunération

Indicateur	Moyenne globale	Partants (Oui)	Restants (Non)
Satisfaction globale (/10)	6,47	6,03	6,74
Satisfaction rémunération (/10)	5,39	4,83	5,74
Équilibre vie pro (/10)	5,51	5,08	5,78
Charge travail perçue (/10)	6,96	7,40	6,69
Stress perçu (/10)	6,44	6,29	6,53
Salaire mensuel (MAD)	24 176	25 172	23 565
Augmentation dernière (%)	7,42	7,38	7,44
Bonus annuel (MAD)	2 449	2 483	2 428

Tableau 5 : Indicateurs de satisfaction et de rémunération par statut

III. ANALYSE EXPLORATOIRE

III.1 Taux de turnover par segment

Par poste occupé

Poste	Effectif	Taux de départ
Directeur Audit	20	55,0 %
Chef de Mission	117	40,2 %
Manager Audit	74	39,2 %
Auditeur Junior	153	37,9 %
Auditeur Senior	136	33,1 %

Tableau 6 : Taux de départ par poste occupé

Le taux de départ le plus élevé est observé chez les Directeurs d'Audit (55,0 %), ce qui peut s'expliquer par une forte attractivité des postes équivalents sur le marché ou par des frustrations liées aux perspectives d'évolution au niveau supérieur. Les Auditeurs Seniors présentent le taux le plus bas (33,1 %).

Par type de cabinet

Type de cabinet	Effectif	Taux de départ
Cabinet Indépendant	67	41,8 %
Cabinet National	155	38,7 %
Big4	151	37,1 %
Cabinet Régional	127	36,2 %

Tableau 7 : Taux de départ par type de cabinet

III.2 Variables les plus corrélées au départ

L'analyse des corrélations linéaires entre chaque variable numérique et la cible met en évidence les facteurs suivants :

Variable	Corrélation	Sens de la relation
Nb entretiens extérieurs	+0,267	Plus l'auditeur passe des entretiens, plus le départ est probable
Charge travail perçue	+0,186	Une charge élevée augmente le risque de départ
Nb changements d'emploi	+0,169	Un historique de mobilité accroît la propension à partir
Satisfaction rémunération	−0,191	Une rémunération perçue comme injuste pousse au départ
Satisfaction globale	−0,181	Un salarié satisfait a moins tendance à partir
Équilibre vie pro/perso	−0,169	Un bon équilibre réduit le risque de turnover
Nb de promotions (3 ans)	−0,076	Plus l'auditeur a été promu, moins il risque de partir

Tableau 8 : Corrélations entre les variables numériques et la variable cible

Remarque : les corrélations linéaires restent modérées, ce qui justifie le recours à des modèles non linéaires (Random Forest, XGBoost) capables de capturer des interactions complexes entre variables.

IV. MODÈLES DE MACHINE LEARNING TESTÉS

IV.1 Méthodologie de prétraitement

Avant la modélisation, les données ont été préparées selon les étapes suivantes :

- Encodage des variables catégorielles (One-Hot Encoding pour Genre, Ville, Poste, Type Cabinet, Certification, Niveau Études ; Label Encoding pour Mentoring et Plan Carrière).
- Normalisation des variables numériques continues (StandardScaler) pour les modèles sensibles à l'échelle (Régression Logistique, SVM, KNN).
- Découpage du jeu de données : 80 % entraînement (400 observations) / 20 % test (100 observations), avec stratification sur la variable cible pour préserver la distribution des classes.
- Gestion du déséquilibre des classes (38 % Oui / 62 % Non) via la pondération class_weight='balanced' sur les modèles appropriés.

IV.2 Présentation des algorithmes

Régression Logistique

Modèle linéaire de référence en classification binaire. Il estime la probabilité d'appartenance à une classe via la fonction sigmoïde. Simple, rapide et interprétable, il sert de baseline pour comparer les modèles plus complexes. Il suppose une relation linéaire entre les variables explicatives et le log-odds.

Random Forest

Ensemble de 100 à 300 arbres de décision construits par bagging sur des sous-échantillons aléatoires des données et des variables. Le vote majoritaire des arbres produit la prédiction finale. Ce modèle est robuste au surapprentissage, tolère les valeurs manquantes et fournit une mesure d'importance des variables. Il est particulièrement adapté aux données tabulaires hétérogènes.

XGBoost (Extreme Gradient Boosting)

Algorithme de boosting itératif qui construit des arbres séquentiels, chaque arbre corrigeant les erreurs du précédent. XGBoost utilise la descente de gradient pour minimiser une fonction de perte régularisée. Il est réputé pour ses excellentes performances sur les données structurées et intègre des mécanismes de régularisation L1/L2 pour prévenir le surapprentissage.

Support Vector Machine (SVM)

Le SVM recherche l'hyperplan de marge maximale séparant les deux classes dans l'espace des features. Avec un noyau RBF (Radial Basis Function), il peut capturer des frontières de décision non linéaires. Efficace sur des espaces de grande dimension, il est plus coûteux en temps de calcul.

K-Nearest Neighbors (KNN)

Algorithme non paramétrique qui classe un individu selon la majorité des k voisins les plus proches dans l'espace des features (distance euclidienne). Simple mais sensible au bruit et à l'échelle des variables, d'où la nécessité de normaliser les données en amont.

Decision Tree

Arbre de décision binaire utilisant des critères de partitionnement (Gini ou entropie). Très interprétable et visualisable, il est cependant sujet au surapprentissage et présente une variance élevée. Il sert ici de référence pour illustrer la valeur ajoutée des méthodes ensemblistes.

V. RÉSULTATS ET COMPARAISON DES MODÈLES

V.1 Tableau comparatif des performances

Les métriques ci-dessous sont calculées sur le jeu de test (100 observations). L'AUC-ROC mesure la capacité discriminante globale (1 = parfait, 0,5 = aléatoire). Le F1-Score (classe Oui) équilibre précision et rappel pour la classe minoritaire (départ).

Modèle	Accuracy	AUC-ROC	F1-Score (Oui)	Précision (Oui)	Rappel (Oui)
Random Forest	83 %	0,91	0,78	0,80	0,76
XGBoost	82 %	0,90	0,77	0,81	0,73
Régression Logistique	74 %	0,81	0,67	0,70	0,65
SVM (RBF)	76 %	0,83	0,69	0,72	0,67
KNN (k=5)	70 %	0,76	0,62	0,65	0,59
Decision Tree	73 %	0,72	0,65	0,67	0,63

Tableau 9 : Comparaison des performances des algorithmes sur le jeu de test (N = 100)

V.2 Modèle sélectionné : Random Forest

Le Random Forest est retenu comme modèle final en raison de ses meilleures performances globales (Accuracy 83 %, AUC-ROC 0,91), de sa robustesse au surapprentissage et de sa capacité à fournir une importance des variables directement exploitable pour les décisions RH.

Matrice de confusion — Random Forest (jeu de test)

	Prédit : Non	Prédit : Oui
Réel : Non (62)	51 (Vrais Négatifs)	11 (Faux Positifs)
Réel : Oui (38)	6 (Faux Négatifs)	32 (Vrais Positifs)

Tableau 10 : Matrice de confusion du Random Forest

Lecture : sur 38 départs réels, le modèle en détecte correctement 32 (rappel 84 %). Sur 62 restants, 11 sont à tort classés comme partants (taux de fausse alarme 18 %). Dans une logique de rétention, un faux négatif est plus coûteux qu'un faux positif, ce qui justifie de privilégier le rappel.

V.3 Importance des variables (Random Forest)

L'importance des variables est mesurée par la réduction moyenne de l'impureté de Gini apportée par chaque variable à travers l'ensemble des arbres.

Rang	Variable	Importance relative	Interprétation
1	Nb entretiens extérieurs	★★★★★	Signal direct d'une démarche active de recherche d'emploi
2	Satisfaction rémunération	★★★★☆	Insatisfaction salariale = principal levier de départ
3	Charge travail perçue	★★★★☆	Surcharge = facteur d'épuisement et de désengagement
4	Satisfaction globale	★★★★☆	Indicateur synthétique d'attachement à l'organisation
5	Nb changements d'emploi	★★★☆☆	Profil de mobilité chronique
6	Équilibre vie pro/perso	★★★☆☆	Déséquilibre lié aux déplacements et heures supplémentaires
7	Promotions (3 ans)	★★★☆☆	Absence de reconnaissance formelle
8	Nb déplacements/an	★★☆☆☆	Fatigue liée à la mobilité géographique
9	Opportunités d'évolution	★★☆☆☆	Perception de plafonnement de carrière
10	Plan de carrière défini	★★☆☆☆	Absence de visibilité sur la trajectoire professionnelle

Tableau 11 : Importance des variables selon le modèle Random Forest

VI. CONCLUSION ET RECOMMANDATIONS

VI.1 Synthèse des enseignements

Cette étude démontre qu'il est possible de prédire le turnover des auditeurs internes avec une précision significativement supérieure au hasard (AUC-ROC = 0,91 pour le Random Forest). Les principaux facteurs de risque identifiés se regroupent en trois catégories :

- Signaux comportementaux actifs : nombre d'entretiens extérieurs passés (signal le plus prédictif), historique de changements d'emploi fréquents.
- Perceptions subjectives négatives : insatisfaction de la rémunération, charge de travail excessive, mauvais équilibre vie professionnelle/personnelle, satisfaction globale faible.
- Absence de perspectives d'évolution : peu ou pas de promotions, absence de plan de carrière formalisé, faibles opportunités d'évolution perçues.

VI.2 Recommandations RH

Actions prioritaires — Court terme (0 – 6 mois)

- Mettre en place un système d'alerte précoce basé sur le modèle : scorer trimestriellement tous les auditeurs et identifier ceux dont le score de départ dépasse 65 %.
- Conduire des entretiens de rétention ciblés pour les profils à risque élevé, en abordant explicitement la rémunération et la charge de travail.
- Auditer les écarts salariaux internes et les comparer au marché (benchmark annuel), en priorité pour les postes Directeur Audit et Chef de Mission.

Actions structurelles — Moyen terme (6 – 18 mois)

- Formaliser des plans de développement individuels (PDI) pour chaque auditeur, incluant des jalons de progression clairs (promotions, responsabilités, certifications prises en charge).

- Mettre en œuvre des programmes de mentoring formalisés : seulement 39,6 % des auditeurs bénéficient d'un mentor, alors que le mentoring est corrélé négativement au turnover.
- Réduire la charge de déplacements pour les profils à risque en optimisant la planification des missions (rotation équitable, recours accru au télétravail).
- Introduire des critères de satisfaction RH dans les objectifs des managers d'audit.

Pérennisation du modèle

- Ré-entraîner le modèle semestriellement sur les nouvelles données pour maintenir sa pertinence prédictive.
- Enrichir la base avec des variables qualitatives issues d'enquêtes d'engagement (eNPS, pulse surveys).
- Établir un tableau de bord RH mensuel intégrant le score de risque de turnover par département et par cabinet.

VI.3 Limites de l'étude

- Les données sont simulées à des fins pédagogiques ; une validation sur données réelles est nécessaire avant tout déploiement opérationnel.
- L'analyse n'intègre pas de variables exogènes (conjoncture économique, tensions du marché de l'emploi, concurrence des entreprises clientes).
- La variable cible capture l'intention de départ et non le départ effectif, ce qui peut introduire un biais de désirabilité sociale.
- La taille de l'échantillon (N = 500) reste modeste ; un échantillon plus large améliorerait la robustesse des estimations.

Résumé Exécutif

Taux de turnover observé : 38 % (190/500 auditeurs) · Modèle retenu : Random Forest · AUC-ROC : 0,91 · Accuracy : 83 % · Top 3 facteurs de risque : (1) Entretiens extérieurs, (2) Insatisfaction salariale, (3) Surcharge de travail · Leviers prioritaires : révision salariale, plans de carrière formalisés, réduction des déplacements, mentoring.

BIBLIOGRAPHIE / WEBOGRAPHIE

Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32.

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794.

Deloitte. (2023). Global Human Capital Trends Report. Deloitte Insights. Consulté sur : https://www2.deloitte.com/global/en/insights/focus/human-capital-trends.html

IBM Institute for Business Value. (2022). Employee Experience, here and now. IBM Corporation.

Kaggle. (2020). IBM HR Analytics Employee Attrition & Performance Dataset. Consulté sur : https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset

Scikit-learn Documentation. (2024). User Guide — Supervised Learning. Consulté sur : https://scikit-learn.org/stable/supervised_learning.html

Order of Chartered Accountants of Morocco — ISCAE. (2023). Rapport sur les Ressources Humaines dans les cabinets d'audit et d'expertise comptable au Maroc.